

Enro-Email

(כאן היו שמות, שמות משתמש ותעודות זהות שהורדתי. זה לא אנונימי, כי השארתי את הלינקים ליוטיוב, אבל לא אוהבת לחלוק תעודות זהות של אנשים)

 Needle Project

קישור לדרייב הקבצים (גדולים מדי למודל ולכן נאלצנו ליצור דרייב) -

תיאור הבעיות (מפורטות בצורה מעמיקה בהמשך המסמך)

הבנת הקהילות בתוך החברה - נרצה להציג ניתוח של הקשרים בין עובדי החברה על מנת לפענח את הקהילות השונות המרכיבות את חברת אנרון. ננסה לאפיין את עובדי החברה בשתי דרכים שונות; באמצעות שמות משתמשים ובאמצעות כתובות מייל. ההבדל בין השניים מתבטא בכך שלמשתמש ספציפי יכולות להיות משויכות כמה כתובות מייל שונות. התבוננות על המשתמשים מעניקה לנו נקודת מבט רחבה יותר קשרים בין עובדים, לעומת זיהוי הקהילות בין כתובות מיילים שתתן לנו מבט ממוקד יותר על הקשרים בין הדומיינים בחברת אנרון.

ניתוח סנטימנטים לאורך זמן - נרצה לנתח את התחושות המשתקפות מהמיילים של עובדי החברה. כך נוכל לבחון את מצב הרוח בתוך החברה ולראות האם ניתן לראות שינוי במהלך השנים החשובות שקדמו לקריסת החברה(1999-2002). את ניתוח זה נעשה באמצעות ספריית vader שהיא ספריית קלח לניתוח טקסט והשוואה של הסנטימנטים השונים למחירי המניות כדי לבדוק האם קיימת קורלציה מסוימת.

השפעה ומרכזיות של יחידים - נעמיק בשאלת הזיהוי והקיטלוג של האנשים המשפיעים ביותר ברשת המיילים שלאנרון באמצעות יצירת רשת ומימוש אלגוריתמי דירוג שונים. רשת זו תהיה גרף מכוון של צמתים כך שכל צומתהוא כתובת מייל וקשת בין צומת 1 לצומת 2 עם משקל כמות המיילים שצומת 1 שלח לצומת 2.

נתונים

מקור - אנחנו משתמשים במאגר הנתונים של מיילים מחברת אנרון, אותו הורדנו מהאתר הבא . גודל - גודל מאגר הנתונים כנ"ל הוא 4.1 ג'יגה המגיע כקובץ CSV.

A file	A message
517401 unique values	517401 unique values
allen- p/_sent_mail/1.	Message-ID: <18782981.1075855378 110.JavaMail.evans@t hyme> Date: Mon, 14 May 2001 16:39:00 -0700 (PDT...
allen- p/_sent_mail/10.	Message-ID: <15464986.1075855378 456.JavaMail.evans@t hyme> Date: Fri, 4 May 2001 13:51:00 -0700 (PDT)...
allen- p/_sent_mail/100.	Message-ID: <24216240.1075855687 451.JavaMail.evans@t hyme> Date: Wed, 18 Oct 2000 03:00:00 -0700 (PDT...

עמודת "file" - היא נתיב הזיהוי של המייל לפי המבנה הבא -
<שם השולח>\<התיקיה בה המיילים נשלחו>\<מזהה ייחודי לאימיילים> (לדוגמה: 1/allen-p/_sent_mail).

עמודת "message" - מכילה בתוכה את כל הפרטים הקשורים להודעות לפי המבנה הבא -

```
1 Message-ID: <18782981.1075855378110.JavaMail.evans@thyme>
2 Date: Mon, 14 May 2001 16:39:00 -0700 (PDT)
3 From: phillip.allen@enron.com
4 To: tim.belden@enron.com
5 Subject:
6 Mime-Version: 1.0
7 Content-Type: text/plain; charset=us-ascii
8 Content-Transfer-Encoding: 7bit
9 X-From: Phillip K Allen
10 X-To: Tim Belden <Tim Belden/Enron@EnronXGate>
11 X-cc:
12 X-bcc:
13 X-Folder: \Phillip_Allen_Jan2002_1\Allen, Phillip K.\Sent Mail
14 X-Origin: Allen-P
15 X-FileName: pallen (Non-Privileged).pst
16 Here is our forecast
```

1. מזהה ייחודי למייל, שנמצא על ידי מערכת הדואר האלקטרוני. הוא עוזר לעקוב אחרי המייל בתוך השרתים
2. התאריך והשעה שבהם נשלח המייל. החותמת בזמן היא לפי אזור זמן מסוים, במקרה הזה - חוף האוקיינוס השקט
3. כתובת הדוא"ל של השולח
4. כתובת הדוא"ל של הנמען
5. שורת הנושא של האימייל. "Re:" מציין שהאימייל הזה הוא תשובה להודעה קודמת עם אותו נושא (יש לציין, לא תמיד יש Re, בהנחה ואין תגובה על ההודעה)
6. מציין את גרסת הפרוטוקול MIME (Multipurpose Internet Mail Extensions) שבה השתמשו, שמאפשר הכללת סוגי תוכן שונים באימייל, כמו טקסט, תמונות וקבצים מצורפים
7. מציין שהתוכן של האימייל הוא טקסט פשוט והקידוד שבו השתמשו הוא US-ASCII, קידוד נפוץ לטקסט באנגלית
8. מציין כיצד תוכן האימייל מקודד לצורך שידור. "7bit" הוא קידוד סטנדרטי לטקסט פשוט
9. כותרת שנוספה על ידי מערכת הדוא"ל כדי לציין במפורש את שמו של השולח
10. כותרת המציינת את שמו של הנמען
- 11+12. כותרות אלה יכללו נמענים שהועתקו (cc) או שהועתקו בסתר (bcc) באימייל, אך במקרה הזה הן ריקות
13. מציין את מבנה התיקיות שבהן נשמר אימייל זה בתוך חשבון הדוא"ל של המשתמש
14. מציין את מקור המייל ומזהה את המשתמש כמחברו
15. שם הקובץ שבו נשמרו האימיילים של המשתמש בפורמט ".nsf" (Lotus Notes) או Notes Storage Facility.
16. בסוף הנתונים האלה כתובה ההודעה שנשלחת לנמענים בתצורת טקסט

ניתוח קהילות בין עובדי אנרון

השערות והערות

בשאלה זו עסקנו בקשרים בין עובדי אנרון המשפיעים ביותר (בפרט בין Users ל-Users ובין כתובות אימייל). ההשערה המרכזית היא שהמיילים נשלחים בעיקר בין חברי אותה מחלקה או צוות, לכן צפינו לראות קהילות חזקות וברורות בין אנשים משפיעים מאותה הקהילה. הגדרת הצלחה ומדידתה הסתמכה על שלושה גורמים עיקריים; מודולריות של הגרפים בתצוגות השונות כדי לוודא מבנה קהילתי חזק; דגימה על הקהילה הגדולה ביותר ויצירת Wordcloud בהתאם על מנת למצוא רמזים לגבי הקשר בין האנשים בקהילה; שימוש במחקרים חיצוניים שנעשו על החברה על מנת לראות אם התוצאות תואמות (לינק: [Connections](#)).

הגדרת הניסויים ואיגוד הנתונים

כחלק מהשאלות השונות על מאגר הנתונים, וכבעיה העיקרית בשאלה זו (חוסר מחלקות ותפקידים של השולחים במאגר הנתונים כולו), מצאנו כי עמודת "file" בטבלה מכילה בתוכה את User ממנו נשלח המייל בעמודת "message". בהסתמך על מידע זה, החלטנו לאגד את כל המיילים שיוצאים מתגיות ה-Users השונים, זאת באמצעות ביטויים רגולריים ופילטרים שונים שעזרו לנקות את תוכן קובץ ההודעה והשאירו אותנו עם נתונים שאפשרו לנו לשלוף רק מיילים שנשלחו בתוך החברה (מיילים עם סיומת "@enron.com"). באופן זה מימשנו ארבעה מילונים בעלי פונקציונליות שונה בהם נשתמש ליצירת הגרפים:

user_connection_dict - מראה את הקשרים בין היוזרים השונים. המילון מאגד תחת כל User את מספר המיילים שיצאו ממנו אל User אחר, זאת ע"י שימוש במילון חיצוני המקטלג כל אימייל ל-User המתאים.

email_connection_dict - מראה את הקשרים בין המיילים השונים. המילון מאגד תחת כל כתובת אימייל את מספר המיילים שיצאו ממנה אל המיילים השונים.

user_messages_dict - מראה את הקשרים בין היוזרים השונים ואת ההודעות שנשלחו. המילון מאגד תחת כל User את כל המיילים שיצאו ממנו אל User אחר, זאת ע"י שימוש במילון חיצוני המקטלג כל אימייל ל-User.

email_messages_dict - מראה את הקשרים בין המיילים השונים. המילון מאגד תחת כל כתובת אימייל את ההודעות השונות שיצאו מהמייל אל המיילים השונים בהתאמה.

תוצאות

הניתוח על Top 50 users מזהה קהילות מרכזיות בקרב עובדי אנרון באמצעות אלגוריתם Louvain, עם ציון מודולריות של 0.62, המצביע על חלוקה טובה של הרשת. נבחרו 50 משתמשים מרכזיים, כולל j-skilling ו-k-lay, שמשפיעים משמעותית על הקשרים הארגוניים. הגרפים מספקים ויזואליזציה אינטראקטיבית של הקהילות, וענן המילים חושף את הנושאים המרכזיים בשיח, של הקהילה הגדולה ביותר מהקהילות שנוצרו כדי להבין טוב יותר את היחס בין העובדים. כמו כן, אפשר לראות כי קהילה אחת יצא כמעט זהה בהירארכיה שלה בחברה כך שכל החברים בה הם תחת pesto-k, למרות שהוא בעצמו אינו חבר בה (ראו מחקר - [Connections](#)). החברים בקהילה הם: thomas-p, saibi-e stepenovitch-j, hernandez-j, white-s, sturm-f, king-j, campbell-l, benson-r.

[קישור לסרטון המסביר כיצד להפעיל את האפליקציה של הויזואליזציות](#)

[קישור לסרטון המראה את הויזואליזציות אם האתר לא עובד](#)

ויזואליזציה

אחד הקשיים שעוררה שאלת זיהוי הקהילות, הוא כיצד לספק ויזואליזציה קוהרנטית עבור גרף המכיל כמות גדולה של קודקודים. תחילה, ניסינו לספק ויזואליזציה בצורה סטטית; כלומר תמונה של גרף התוצאה. כיוון זה התברר כשגוי, שכן גרף עם כמות גדולה של קודקודים הוא עמוס מכדי להבין דבר. על כן, החלטנו להציג את התוצאות בכמה דרכים אינטראקטיביות ולעטוף אותן תחת אתר, שמומש באמצעות ספריית Streamlit. באמצעות ספרייה זו, הוספנו משתנים דינמיים שונים המאפשרים לשנות את הגדרות הגרפים ולקבל תוצאות מעניינות בהתאם (כגון כמות אנשים שעליהם נבצע את הניסויים שלנו, מרחק בין קודקודים, מס' שליפה של צלעות בגרמן ניומן ושינוי מספר הצלעות המינימלי שמגדיר קשר בין Users או בין Emails). להלן פירוט על הגרפים השונים:

גרף תלת-מימדי של קהילות פנימיות - החלטנו שצורת התצוגה המעניינת והברורה ביותר להציג את הקהילות השונות, היא באמצעות גרף תלת-מימדי שמראה את הקשרים הבלעדיים בין האנשים בכל קהילה (כלומר אין צלעות בין קהילות אלא רק בין אנשים באותה הקהילה). אל גרף זה הוספנו מקרא מתאים, שמפרט בצורת רשימה על כל המשתתפים בכל אחת מהקהילות השונות.

אלגוריתמים: Louvain, Girvan Newman כלים: networkx, plotly, pandas, community, numpy

דנדרוגרם - בנוסף לתצוגת הקשרים בין אנשים באותה הקהילה, החלטנו שחשוב להציג גם את היחסים היררכיים בין הקהילות. תצוגה זו מסייעת להראות כיצד תתי קהילות קטנות משתלבות בתוך קהילות גדולות יותר ומספקת לנו נקודת מבט גדולה יותר על הקשרים של האנשים המשפיעים בחברה ואת יחסם.

אלגוריתמים: Louvain, Girvan Newman כלים: networkx, plotly, pandas, scipy, community, numpy

ענן מילים - כדי לספק נקודת מבט נוספת שייתכן ותעזור לזהות אם קהילות זוהו כשורה, החלטנו שנכון יהיה להראות את המילים המרכזיות של הקהילה הגדולה ביותר בגרף. ניתוח של ענן המילים הזה עשוי לספק לנו מילים שונות מהן ניתן להסיק (או לפחות לנסות להסיק) מה הקשר בין האנשים בקהילה.

אלגוריתמים: Text preprocessing, Wordcloud כלים: re, matplotlib, WordCloud, community, numpy

ניתוח מרכזיות של כתובות משפיעות ביותר

השערות והערכות

בשאלה זו נרצה להבין, על ידי יישום אלגוריתם PageRank, מי הן הדמויות המרכזיות ברשת הדוא"ל של אנרון. הגדרת הצלחה תוגדר כזיהוי נכון של האנשים המרכזיים ברשת הארגונית והיכולת שלהן לגשר בין גורמים אחרים. כדי להבין האם תוצאות הגרף המתקבל מאלגוריתם הדירוג הן אכן תוצאות איכותיות נרצה ליצור גרף ולהשוותו אל מול נתונים אמיתיים (מצורף בקישור בשאלה על זיהוי הקהילות בחברה). יתר על כן, כדי להוסיף לדיוק המידע המתקבל, ננתח את מרכזיות betweenness על האנשים הדומיננטיים שהאלגוריתם מצא, זאת כדי להבין כיצד משמשים כמתווכים בין צמתים אחרים ברשת.


הגדרת הניסויים ואיגוד הנתונים

גם כאן, הבעיה העיקרית הייתה ניקוי המיילים. כדי לבצע זאת, גם כאן נעזרנו בביטויים רגולריים ופילטרים שונים שעזרו לנקות את תוכן קובץ ההודעה והשאירו אותנו עם נתונים שאפשרו לנו לשלוף רק מיילים שנשלחו בין האנשים בחברה (מיילים עם סיומת "@enron.com"). בניגוד לשאלת זיהוי הקהילות, כאן אנחנו לא יוצרים מילון, אלא עובדים ישירות על עמודת ה"message" במאגר הנתונים שלנו וממנה מפיקים גרף מכוון בו צמתים מייצגים אנשים וקשתות מייצגות תקשורת ביניהם, כאשר כל קשת בין צומת 1 לצומת 2 תהיה צומת מכוונת אם צומת אחד שלח מייל לצומת 2 וכן משקל הקשת יהיה ככמות המיילים שנשלח מצומת 1 לצומת 2.

לבסוף, ביצענו את אלגוריתם PageRank לחישוב מרכזיות של כל אדם ברשת ולאחר מכן יישום מרכזיות betweenness על תת גרף של אנשים משפיעים ביותר, עפ"י תוצאות דירוגי האלגוריתם, זאת בכדי לזהות דמויות שמחברות בין חלקים שונים בתת רשת.

תוצאות

PageRank - בגרף התוצאה זוהו 15 הדמויות המרכזיות ברשת הדוא"ל של Enron. הדמות Tana Jones נמצאה בעלת הדירוג הגבוה ביותר, ואחריה Sara Shackleton ו-Gerald Nemec. דמויות אלו מופיעות במרכז הרשת שנוצרה באמצעות אלגוריתם הדירוג PageRank והן משקפות את תפקידן החשוב בארגון.



Betweenness Centrality - בין הדמויות הבולטות ב-Betweenness, הדמויות Jeff Dasovich ו-Daren Farmer נמצאו כבעלי ערכי Betweenness גבוהים, כלומר משמשים כמתווכים מרכזיים ברשת על פי תוצאת האלגוריתם למציאת Betweenness.

Top 15 Nodes by PageRank with Metrics

Email	PageRank	In-Degree	Out-Degree	Betweenness Centrality
tana.jones@enron.com	0.006737799294767702	586	702	0.14835164835164835
sara.shackleton@enron.com	0.0063061980409289215	629	612	0
gerald.nemec@enron.com	0.005071946721559095	500	455	0.1263736263736264
mark.taylor@enron.com	0.004629007490453339	500	425	0.21153846153846156
louise.kitchen@enron.com	0.004524603819836328	664	454	0.1208791208791209
jeff.dasovich@enron.com	0.004047294523020519	619	871	0.02197802197802198
sally.beck@enron.com	0.003764168487062057	566	1212	0.26373626373626374
vince.kaminski@enron.com	0.003630300351128313	394	706	0.07142857142857144
kay.mann@enron.com	0.0036015114974075643	373	443	0.1565934065934066
kenneth.lay@enron.com	0.003478270105752905	562	1040	0.13186813186813187
chris.germany@enron.com	0.0032618352517274785	337	433	0.08791208791208792
benjamin.rogers@enron.com	0.0031044631549542747	307	259	0.005494505494505495
daren.farmer@enron.com	0.003010974209088744	226	179	0.1208791208791209
john.lavorato@enron.com	0.002976919824318661	496	406	0.17857142857142858
jeff.skilling@enron.com	0.0028486463986022977	442	314	0.23626373626373628


ויזואליזציה

בחרנו בגרפים ובטבלאות אלו כדי להמחיש בצורה ברורה את המבנה והקשרים ברשת התקשורת של Enron, תוך הדגשת המרכזיות של הדמויות המרכזיות לפי PageRank ו-Betweenness. השילוב בין גרפים לטבלאות נותן הבנה ויזואלית ומספרית של המרכזיות ושל הקשרים בין הדמויות ברשת.

כלים: networkx

אלגוריתמים: Betweenness, PageRank

Top 30 Nodes by PageRank



Top 30 Nodes by PageRank with Metrics

Email	PageRank	In-Degree	Out-Degree	Betweenness Centrality
tana.jones@enron.com	0.006737799294767702	586	702	0.12495894909688016
sara.shackleton@enron.com	0.0063061980409289215	629	612	0.004720853858784894
gerald.nemec@enron.com	0.005071946721559095	500	455	0.07520525451559934
mark.taylor@enron.com	0.004629007490453339	500	425	0.013136288998357963
louise.kitchen@enron.com	0.004524603819836328	664	454	0.07922824302134644
jeff.dasovich@enron.com	0.004047294523020519	619	871	0.08661740558292282
sally.beck@enron.com	0.003764168487062057	566	1212	0.15004105090311987
vince.kaminski@enron.com	0.003630300351128313	394	706	0.12368637110016419
kay.mann@enron.com	0.0036015114974075643	373	443	0.025533661740558294
kenneth.lay@enron.com	0.003478270105752905	562	1040	0.02647783251231527
chris.germany@enron.com	0.0032618352517274785	337	433	0.0332512315270936
benjamin.rogers@enron.com	0.0031044631549542747	307	259	0.10529556650246304
daren.farmer@enron.com	0.003010974209088744	226	179	0.011699507389162561
john.lavorato@enron.com	0.002976919824318661	496	406	0.2520114942528736
jeff.skilling@enron.com	0.0028486463986022977	442	314	0.1488095238095238
steven.kean@enron.com	0.002532493518276848	394	339	0
rod.hayslett@enron.com	0.0024950884060431864	356	284	0.08825944170771757
greg.whalley@enron.com	0.0024746053780794535	433	105	0.012602627257799672
don.baughman@enron.com	0.0023619629147949403	279	185	0.09913793103448275
richard.shapiro@enron.com	0.002285919626081345	417	313	0
ebass@enron.com	0.0022855822054996273	58	1	0
elizabeth.sager@enron.com	0.002086078396723899	366	293	0.2614942528735632
vkamins@enron.com	0.002044436127447968	170	0	0
kimberly.watson@enron.com	0.0019399036239084956	266	221	0.0166256157635468
j.kaminski@enron.com	0.0018945319252191913	264	259	0.41128899835796384
mike.mcconnell@enron.com	0.001802694941438796	291	337	0
michelle.lokay@enron.com	0.001795948994538437	230	113	0
vince.j.kaminski@enron.com	0.001718744336511431	150	2	0
john.arnold@enron.com	0.0016554725102006823	244	237	0.0014778325123152708
john.griffith@enron.com	0.0016269743009404483	232	88	0

סיכום תוצאות הגרפים - ניתן לראות באופן גורף, ובכל הוויזואליזציות, את הדמויות המרכזיות ברשת התקשורת של Enron לפי ערכי PageRank ו-Betweenness. הגרפים של ה-15 וה-30 מציגים את הדמויות והקשרים ביניהן, כאשר הצבע והגודל של הצמתים משקפים את רמת המרכזיות שלהן. הטבלאות מציגות נתונים מספריים של שני האלגוריתמים כנ"ל, ומאפשרות לזהות ולהשוות את הדמויות המשפיעות ביותר ברשת הארגונית. לדוגמה, Tana Jones מופיעה כדמות מרכזית עם ערך PageRank גבוה, מה שמעיד על כך שהיא הייתה דמות משמעותית בתקשורת הארגונית. לעומתה, Jeff Dasovich ו-Daren Farmer מופיעים כבעלי ערכי Betweenness גבוהים, מה שמצביע על תפקידם החשוב כמתווכים ומקשרים בין חלקים שונים ברשת.

ניתוח סנטימנטים לאורך זמן



השערות והערות

ההשערה המרכזית בשאלה זו היא שהתחושות בחברה השתנו באופן דרסטי בחודשים הקודמים לסגירתה. על כן, נגדיר הצלחה כיכולת ליצור מדד רגשי מדויק עבור הודעות דוא"ל לאורך השנים והתאמתן לתוצאה. כדי לוודא את נכונות התוצאות נסווג מיילים חריגים, כלומר בעלי דירוג חיובי/שלילי גבוה, נבצע ויזואליזציה בענן ונבחן אם התוצאות אכן תואמות את ההערכה. כדי לוודא שתוצאות ניתוח הסנטימנטים אינן מקריות, נבצע את הניתוח על כמות גדולה של הודעות לאורך זמן (כ-430 אלף הודעות מייל עם סיומת של החברה) כדי לוודא את איכות ודיוק התוצאות על הקלטים השונים (ההודעות השונות).

הגדרת הניסויים ואיגוד הנתונים

לאחר ניקוי הדאטה בצורה יסודית ואיסוף של מיילים שיצאו מכתובות של החברה בלבד כמוזכר בסעיפים הקודמים, ביצענו הסרה של הודעות כפולות ושרשרות מיותרים. לאחר מכן, השתמשנו ב-VADER כדי להבטיח דיוק מיטבי בניתוח הסנטימנטים (למרות המחיר היקר בזמן הריצה). על התוצאות ביצענו שילוב נתונים נוספים כמו מחירי מניות כדי לבדוק קשרים פוטנציאליים ולבסוף בדיקת סנטימנטים בעלי סיווגים קיצוניים בענן מילים כדי לבדוק שהסיווג נעשה בצורה אחידה ותקינה.


תוצאות




ממוצע הסנטימנטים מ-1999 עד 2002 הראה שינוי ניכר, בעיקר לקראת קריסתה. הקורלציה של הסנטימנטים למחירי המניות הראתה קשר בינוני חיובי, המעיד על ההשפעה החלקית של מחירי המניות על רגשות העובדים. בשנת 2001, בשנת הקריסה, ניתן להבחין כי הסנטימנטים לא היו קונסיסטנטיים - החלו מירידה חדה בחודש הראשון עד לחודש הרביעי, עלייה חדה בין החודש הרביעי לחודש החמישי, ירידה חדה במשך ארבעה חודשים לקראת הקריסה ולבסוף עלייה מונוטונית עד לסוף השנה. סה"כ ניתן לראות שממוצע הרגשות בין השנים מתחיל בעלייה עד שנת 2000 ואז בירידה עד סוף שנת 2002. יתר על כן, נשים לב כי כל הממוצעים הם בגבול החיובי (למרות שהרבה הודעות מכילות ציון שלילי ממש אבל באופן יחסי לא נתקלנו בהמון)

ויזואליזציה

התוצאות השונות הראו את מגמת הרגשות של מיילים לאורך השנים והחודשים. בנוסף, בוצע פלוט המראה את הקורלציה בין הסנטימנט למחירי המניות. הבחירה בפלוטים אלו עוזרת להמחיש את השינויים ברגש בנוגע למצב החברה. בבחירת הויזואליזציה, בחרנו להראות נתונים בסיסיים כמגמת הרגשות בממוצע לאורך זמן (גם לפי שנה וגם לפי חודש), ולפיהם לפענח את תוצאות הניסוי. בנוסף מימשנו ויזואליזציה משולבת גרפים (שני גרפים במקביל) המציגה את הקשר בין מחירי המניות של החברה לבין הסנטימנט מ-1999 עד 2001. *אלגוריתמים: Text preprocessing, Linear Regression, matplotlib, vaderSentiment, scipy, plotlib* כלים:






הפלוטים מציגים את מגמות הסנטימנט במחירי המניות לאורך השנים 1999-2002. ניתן לראות כי במהלך השנים 1999-2000 יש יציבות יחסית בסנטימנט, בעוד שבשנים 2001-2002, הפלוטים מראים מגמות כלליות של קשר בין סנטימנט לבין מחירי המניות. ישנה קורלציה חיובית (0.48) בין ממוצע הסנטימנט לממוצע מחירי המניות, מה שמרמז על כך שכלל שהסנטימנט במיילים היה חיובי יותר, מחירי המניות נטו לעלות, ולהפך. הסנטימנט משתנה בצורה עקבית עם מגמות השוק, כשהירידות ברגשות חופפות לתקופות של ירידות חדות במחירי המניה.

[illegible][illegible]

Most Frequent Words in Highly Positive Emails



Most Frequent Words in Highly Negative Emails



[illegible]

הקשיים בשאלות ופתרונותם

בשאלות השונות התעסקנו רבות עם ניתוח אינטראקציות פנימיות של עובדים בחברת אנרון. אחד הקשיים המרכזיים היה להתמודד עם הדאטה עצמו, זאת כיוון שהגיע "מלוכלך" מאוד. תחילה, סינון כתובות מיילים שאינם של אנרון וסינון תוכן המיילים שנשלחו היוו אתגר מרכזי, זאת בשל חוסר אחידות בפורמט של כתובות המיילים ותוכם. עובדה זו דרשה מאיתנו להבין את המבנה המורכב של המיילים (מפורט בתמונות) בכדי לבצע שלפוט מדויקות, שווידאו כי כתובות המיילים תקינות ושייכות לחברת אנרון בלבד, והמיילים שנשלחו נקיים מחלקים שעלולים להפריע לניתוחים השונים. שלב זה היה קריטי על מנת להגיע לתשובה איכותית ומדויקת, כיוון שסינון לא נכון יוביל להיעדר נתונים רלוונטיים ולשיבוש התוצאות הסופיות. כדי לפתור זאת, יצרנו פילטרים מבוססים ביטויים רגולריים, מילות קישור באנגלית ומופעים חוזרים של טקסט שעזרו לנו לתחום את תוכם של המיילים.

קושי מרכזי נוסף בו נתקלנו היה כיצד להגדיר הצלחה של השאלות השונות. הסיבה העיקרית שהצלחה היוותה מכשול, נבעה מחוסרים רבים במאגר הנתונים וקושי בווידוא תחושות. בשאלת ניתוח הקהילות, מבנה המייל לא הכיל את התפקידים והמחלקות של המוען והנמענים. עובדה זו הקשתה עלינו לקטלג את האנשים בחברה תחת קהילות ואילצה אותנו להגדיר קשרים ולחבר בין יוזרים בצורה שונה. כדי להבין אם התוצאות מתיישבות נכונה עם האמת בשטח, נעזרנו במקורות חיצוניים, כגון מחקרים המפרטים את הקשרים בחברה, וביצענו Wordcloud עבור קהילות שונות על מנת למצוא רמזים אופציונליים לגבי הקשר ביניהם. בשאלת ניתוח הסנטימנטים, התקשנו להבין האם התוצאות נכונות, שכן אין דרך לדעת את מצב הרוח האמיתי של העובדים. כדי לפתור זאת ניסינו לקשר בין אירועים משמעותיים כגון מחיר המנייה של אנרון באינטרוולים בהם היה שינוי דרסטי בתחושות ולהבין את הקורלציה ביניהם ואם בכלל קיימת או לבדוק את ענן המילים של קפיצה חדה בערכי הסנטימנטים ולבדוק האם חיובי או שלילי.

עבודה עתידית

נציע כמה רעיונות נחמדים שיכולים להיות מעניינים ונחמדים למימוש.
סיווג מיילים - סיווג מיילים למיילים מקצועיים, מיילים אישיים מיילי ספאם ועוד קטגוריות.
מודל ניבוי - סיכוי שתגובה למייל מסוים תתקבל, באמצעות פרמטרים כמו תכנים, סטטיסטיקות היסטוריות וכו..
סיכום מיילים - יצירת מערכת המסכמת מיילים ארוכים או תכתובות מרובות, תוך שימור המידע החשוב והעיקרי.

סיכום

בפרויקט שלנו התמקדנו בשלוש שאלות מרכזיות:
ניתוח קהילות בחברה, ניתוח סנטימנטים ברשת התקשורת של חברת אנרון וזיהוי אנשים משפיעים. ביצענו ניתוח קהילות כדי לזהות קבוצות חזקות בתוך החברה והבנו מי הדמויות המרכזיות שהיו בעלות השפעה משמעותית. השתמשנו באלגוריתמים שונים כדי לדרג דמויות מרכזיות ולזהות מתווכים חברתיים חשובים. לבסוף, ניתחנו את התחושות המשתקפות במיילים של החברה לאורך השנים והחודשים, ואת תוצאות הסנטימנטים השונים השוינו למחירי המניות ואיתו מצאנו קשר חיובי בינוני בין התחושות למחירי המניות. למדנו המון ובהחלט שברנו את הראש לא מעט, וכבר מחכים לאתגר הבא.